

RNN (Recurrent Neural Network)

순환 신경망과 시퀀스 데이터 처리의 기본 개념

발표자: 손범수

RNN이란?

정의

RNN이란 Recurrent Neural Network의 약자로, 순환 신경망을 뜻한다.

시퀀스 처리

RNN은 입력과 출력을 시퀀스 단위로 처리한다.

시퀀스 모델

시퀀스란 문장처럼 단어가 순서대로 나열된 데이터를 뜻하며
이러한 시퀀스를 처리하기 위해 고안된 모델을 시퀀스 모델이라고 한다.
RNN은 그중에서 딥러닝의 가장 기본적인 시퀀스 모델이다.

메모리 셀과 은닉 상태

셀

RNN의 은닉층에서 활성화 함수를 통해 결과를 내보내는 역할을 하는 노드를 셀이라고 한다.


메모리 셀

이 셀은 이전의 값을 기억하려고 하는 일종의 메모리 역할을 수행하므로 메모리 셀이라고 부른다.

은닉 상태

은닉층의 메모리 셀에서 나온 값이 다음 은닉층의 메모리 셀에 입력되는데, 이 값을 은닉 상태라고 한다.

RNN의 입력 구조



현재 입력과 이전 정보


RNN의 각 셀은 현재의 입력 값과 이전의 메모리 셀 출력 값을 함께 입력으로 사용한다.

이전 시점의 정보가 다음 시점으로 계속 전달되기 때문에, RNN은 단순히 현재 값만 보는 것이 아니라 과거의 흐름까지 반영할 수 있다.

의의

이 구조 덕분에 문장, 음성, 시계열 데이터처럼 순서가 중요한 데이터를 효과적으로 처리할 수 있다.

일 대 다



일 대 다(one-to-many)

의미

하나의 입력에 대해 여러 개의 출력을 가지는 구조이다.

Ex)

하나의 이미지 입력에 대해서 사진의 제목을 출력하는 이미지 캡셔닝에 사용할 수 있다.

다 대 일



의미


시퀀스 입력에 대해서 하나의 출력을 하는 구조이다.

Ex)

입력 문서가 긍정적인지 부정적인지 판별하는 감성 분류
정상 메일인지 스팸 메일인지 분류하는 스팸 메일 분류

다 대 다 (Many-to-Many)

개체명 인식



다 대 다(many-to-many)

의미


시퀀스 입력에 대해 시퀀스 출력을 하는 구조이다.

Ex)

다 대 다 모델은 챗봇이나 번역기에 많이 쓰인다.

개체명 인식이나 품사 태깅과 같은 작업

RNN의 학습



x_t : 현재 시점의 입력값
 s_t : 현재 시점의 은닉상태
 o_t : 현재 시점의 출력값
 U, V, W : 가중치


BPTT

RNN의 학습에는 back propagation의 확장인 BPTT가 사용된다.

BPTT란?

재귀적인 형태의 모델을 시간에 대해 펼쳐서 현재 시점의 에러를 최초 시점까지 전파해 학습하는 것

RNN의 학습



$$E_t(y_t, \hat{y}_t) = -y_t \log \hat{y}_t$$

-> 각 시점의 Error를 나타낸 식


$$E(y, \hat{y}) = \sum_t E_t(y_t, \hat{y}_t)$$

-> Total loss는 이전의 모든 시점의 Error를 합한 값을 나타낸 식

E : 각 시점의 Error

BPTT의 동작 방식

Ex) $t = 3$ 시점에서 BPTT가 이루어지는 예시



$$\frac{\partial E_3}{\partial W} = \frac{\partial E_3}{\partial \hat{y}_3} \frac{\partial \hat{y}_3}{\partial s_3} \frac{\partial s_3}{\partial W}$$

$$s_3 = \tanh(U x_3 + W s_2)$$

$$\frac{\partial E_3}{\partial W} = \sum_{k=0}^3 \frac{\partial E_3}{\partial \hat{y}_3} \frac{\partial \hat{y}_3}{\partial s_3} \frac{\partial s_3}{\partial s_k} \frac{\partial s_k}{\partial W}$$

- 가중치 W 가 모든 시점에서 메모리 셀의 출력 값(s)을 구할 때 사용되었기 때문에 수식에서 처럼 $k=0$ 부터 3까지 계산하여 합하는 것
- 이렇게 학습 시에 앞의 시점으로 계속 전파가 일어나는데 전파가 길어질수록 기울기 값이 0에 가까워지게 되는 기울기 소실 문제가 발생하게 된다.

LSTM이란?

LSTM

Long Short-Term Memory의 약자로, RNN 계열의 순환 신경망 구조이다.

시계열 데이터 예측, 자연어 처리, 음성 인식처럼 순서가 중요한 데이터 처리에 사용된다.

RNN의 한계

기본 RNN은 입력 시퀀스가 길어질수록 앞쪽 정보를 잘 기억하지 못하는 문제가 있다.

이 문제는 역전파 과정에서 기울기가 작아지는 Gradient Vanishing Problem과 관련이 있다.

LSTM을 왜 쓰는가?

기본 RNN의 한계를 극복하기 위해 오래 기억해야 할 정보와 버려야 할 정보를 게이트를 통해 선택적으로 조절한다.

LSTM의 구조


Memory Cell

LSTM은 이전 정보를 오래 보존하기 위한 Memory Cell을 가진다.

이 Memory Cell은 RNN과 달리 셀의 값을 얼마나 기억할지 결정하는 것이 가능한 게이트를 가지고 있어서 필요한 정보만 기억할 수 있도록 제어할 수 있다.

세 가지 Gate

Input Gate, Forget Gate, Output Gate가 Cell State의 정보를 조절한다.



Cell State

Cell State란?

Cell State는 이전 시점에서 현재 시점까지 유지되는 정보의 흐름을 의미한다.

오래된 정보를 보존하면서도 현재 입력에 따라 필요한 정보는 새롭게 갱신할 수 있다.


업데이트 과정

Cell State는 Forget Gate와 Input Gate를 거치면서 두 번 변화한다.

첫째, 이전 정보 중 필요 없는 정보를 줄인다.

둘째, 현재 입력에서 필요한 새로운 정보를 더한다.

이 과정을 거쳐 만들어진 새로운 Cell State가 다음 시점으로 전달된다.



Forget Gate


Forget Gate란?

Forget Gate는 이전 Cell State의 정보를 지울 것인지 유지할 것인지 결정한다.
즉, 과거 기억 중 현재 시점에서 불필요한 정보를 걸러내는 역할을 한다.

동작 방식

현재 입력 x_t 와 이전 은닉상태 h_{t-1} 을 이용해 f_t 값을 만든다.
활성화 함수로 sigmoid함수를 사용하므로 f_t 는 0과 1 사이의 값을 가진다.
값이 0에 가까우면 해당 정보는 거의 사라지고, 1에 가까우면 그대로 유지된다.

$$f_t = \sigma(W_{xf}h_{t-1} + W_{xf}x_t)$$



Input Gate

Input Gate란?

Input Gate는 현재 입력에서 들어온 새로운 정보를 Cell State에 얼마나 반영할지 결정한다.

이를 통해 LSTM은 기존 기억과 새로운 정보를 적절히 조합할 수 있다.

두 가지 계산

sigmoid 함수는 새로운 후보 정보 중 얼마나 전달할지를 결정한다.


tanh 함수는 Cell State에 추가할 새로운 후보 정보를 만든다.

두 값을 곱한 뒤 Cell State에 더하면 다음 단계로 전달될 Cell State C_t 가 만들어진다.

$$i_t = \sigma(W_{hi}h_{t-1} + W_{xi}x_t)$$

$$\hat{c}_t = \tanh(W_{hc}h_{t-1} + W_{xc}x_t)$$

$$C_t = C_{tf} \oplus i_t \otimes \hat{c}_t$$



Output Gate

Output Gate란?

Output Gate는 Cell State에 저장된 정보 중 현재 시점의 출력으로 사용할 정보를 결정한다.
Cell State 전체를 그대로 출력하지 않고, 필요한 부분만 조절해서 은닉상태로 내보낸다.

동작 방식

먼저 Cell State에 $\tanh$ 함수를 적용해 출력 후보 값을 만든다.

그다음 현재 입력과 이전 은닉상태에 sigmoid 를 적용해 0과 1 사이의 조절 값을 만든다.

출력 후보 값과 조절 값을 곱해 크기를 조절하면 현재 시점의 은닉상태가 된다.

$$O_t = \sigma(W_{ho}h_{t-1} + W_{xo}x_t)$$

$$h_t = O_t \otimes \tanh(c_t)$$

